EM8BTEM - UPS Toulouse

Introduction à la Modélisation Moléculaire

Georges Czaplicki, UPS / IPBS-CNRS cgeorge@ipbs.fr, tél. : 05 61 17 54 04

Quels sont les domaines d'application de la MM?

La MM cherche les réponses aux questions, concernant la nature et le fonctionnement de divers systèmes biologiques. Par exemple, elle peut faciliter la compréhension de :

- structures d'équilibre des sous-unités de biopolymères,
- aspects énergétiques de la formation de ponts d'hydrogène dans les protéines et les acides nucléiques,
- cinétique du repliement de protéines,
- le fonctionnement des agrégats supramoléculaires.

Les approches basées sur la modélisation sont nécessaires pour mieux comprendre le fonctionnement de systèmes biologiques et pour concevoir les théories, qui fourniront les prédictions (à tester expérimentalement!).

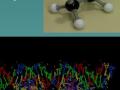
Qu'est-ce que c'est la MM?

La modélisation moléculaire (MM) permet d'étudier la structure et la fonction de molécules grâce à la construction de modèles et au calcul de leur propriétés.

Les modèles peuvent être simple, comme une représentation "ball and stick«, ou une image animée sur l'écran d'ordinateur.

Le calcul couvre les sujets divers :

- mécanique quantique ab initio et semi-empirique
- mécanique moléculaire empirique
- dynamique moléculaire
- méthodes statistiques (Monte Carlo)
- calcul d'énergie libre
- relation structure-activité (SAR)
- information chimique/biochimique
- bases de données
- utilisation de données expérimentales (RMN, RX) pour la détermination de structures moléculaires



Quels sont les avantages de la MM?

Pour comprendre le fonctionnement de molécules biologiques, il faut d'abord déterminer leurs structures tridimensionnelles. Les techniques expérimentales, comme la RMN ou les rayons X, nécessitent beaucoup de temps (et d'argent). Elles ont aussi leurs problèmes, qui limitent les champs de leurs applications.

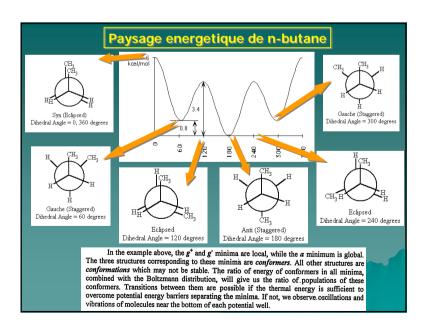
Par conséquent, les approches basées sur la modélisation et le calcul deviennent les options extrêmement attractives.

Un exemple : le développement de nouveaux médicaments.

La recherche de ligands de haute affinité pour les récepteurs sélectionnés passe par le criblage haut débit, implique la synthèse chimique et le filtrage de molécules, et finalement nécessite plusieurs années des essais cliniques.

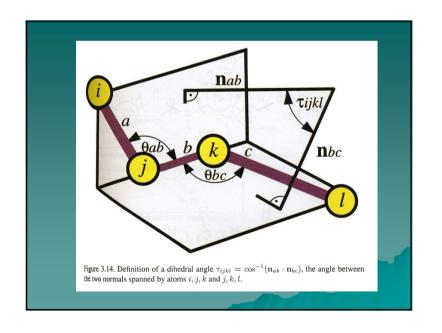
La totalité de la procédure peut durer jusqu'à 15 ans et couter ~1 milliard d'euros. L'approche basée sur la MM peut raccourcir la procédure à quelques années seulement et permet d'économiser les sommes importantes.

Cuels sont les dangers de la MM? La MM est basée sur les multiples approximations. Leur connaissance détaillée est indispensable, surtout dans le contexte scientifique pertinent. Watson et Crick avec le modèle de l'ADN à 2 hélices Pauling et Corey avec leur modèle de l'ADN à 3 hélices



Références générales

- T. Schlick, *Molecular Modeling and Simulation*. Springer-Verlag New York, Inc., 2002. [Interdisciplinary guide to biomolecular modeling]
- A. R. Leach. Molecular Modelling. Principles and Applications.
 Addison Wesley Longman, Essex, England, 1996.
 [Broad introduction to many aspects of molecular modeling and computational chemistry techniques]
- M.P. Allen and D.J. Tildesley. Computer Simulation of Liquids. Oxford University Press, New York, 1987.
 [Good advanced reference book for molecular simulations]
- G.E. Schulz and R.H. Schirmer. Principles of Protein Structure.
 Springer Advanced Texts in Chemistry, Springer-Verlag, New York, 1990.
 [Advanced text on the rapidly-changing field of protein folding]



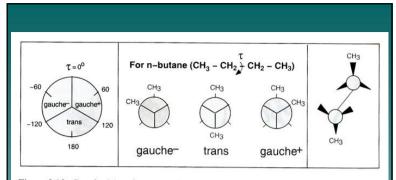
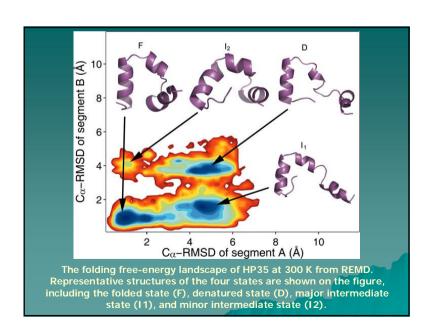
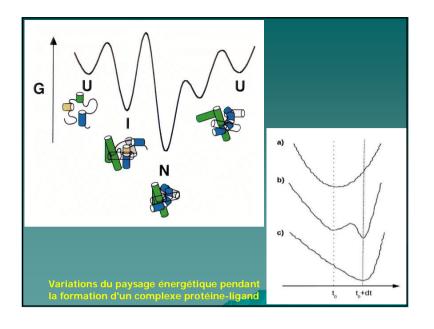
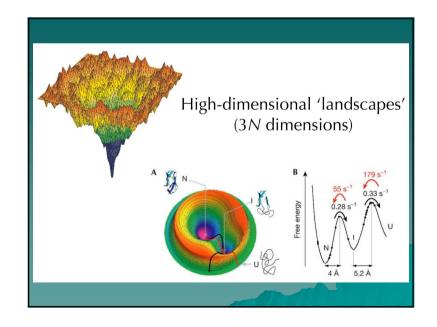


Figure 3.13. *Gauche* (g) and *trans* (t) dihedral-angle orientations for *n*-butane: (left) classification wheel; (middle) simple Newman projections that illustrate the three favored orientations of the two end methyl groups about the central C–C bond (perpendicular to the plane of the paper); and (right) the *trans* conformation, which has the least steric clashes.







Molecular Geometry and Energy

Molecular Mechanics (MM) focuses on determining parameters such as: - molecular structures and energies,

- transition states, relative conformer populations and energies,
- harmonic vibrational frequencies.

Quantum mechanics (QM) should be able to provide tools for calculating molecular structures and energies. But even in the non-relativistic approach an accurate description of a multi-atomic system is too complex. In the Schrödinger equation:

$$H\psi(r,R) = E\psi(r,R)$$

the wave function ψ depends on nuclear coordinates R as well as on electronic coordinates r. In 1927 Born and Oppenheimer simplified the analysis by separating the movements of nuclei and electrons. With this approximation, two equations result:

1. potential energy surface

$$H\psi(r;R) = E\psi(r;R)$$

where the wave function ψ describes electrons and depends parametrically on nuclear coordinates R. This is the definition of the potential energy surface. There are two major approaches to solve this problem:

a) ab initio calculations (Gaussian, Cadpac, Hondo, GAMESS, Dmol, ...)

If N is the number of atoms in a molecule, the computation time is roughly proportional to N4, which limits the applicability of this approach.

Champs de force

- 1. Objectif: interpolation & extrapolation
- 2. Paramétrisation: ajustement multiparametrique et vérification du modèle
- 3. Forme générale :

$$V = \sum V_{\it stretch} + \sum V_{\it bend} + \sum V_{\it torsion} + \sum V_{\it vdW} + \sum V_{\it Coulomb} + ...$$

- Déviations par rapport aux paramètres "idéaux"
- Valide pour une classe particulière de molécules

Molecular Geometry and Energy

b) semi-empirical calculations (CNDO, MINDO, MOPAC, AMPAC,...)

Since some of the overlap integrals take time to calculate, a considerable gain is expected when integrals of the type:

$$\int\limits_{-\infty}^{\infty}\int\limits_{-\infty}^{\infty}\int\limits_{-\infty}^{\infty}\int\limits_{-\infty}^{\infty}\int\limits_{-\infty}^{\infty}\int\limits_{-\infty}^{\infty}\psi_{1}(1)\psi_{2}(1)\frac{1}{r_{12}}\psi_{3}(2)\psi_{4}(2)dx_{1}dy_{1}dz_{1}dx_{2}dy_{2}dz_{2}$$

can be replaced by some empirical factors, carefully chosen to reproduce the ab initio results. In the above, the wave function subscripts refer to orbitals and (1) and (2) are electron indices. These integrals can be grouped in families and a decision has to be made which group to omit in the calculations. This justifies the existence of numerous semi-empirical methods.

2. quantum dynamics

The second equation gives us the structure and time evolution of a molecule:

$$H\Phi(R) = E\Phi(R)$$

The above describes the motion of nuclei on the electronic potential energy surface. But we need the empirical fit to the potential surface! Since nuclei move slowly, we can replace the Hamiltonian above by the Newton's equations of motion:

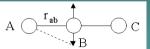
$$m\frac{d^2R}{dt^2} = -\frac{dV}{dR}$$

Its solution with empirical fit to the potential surface V is called molecular dynamics.

Champs de force

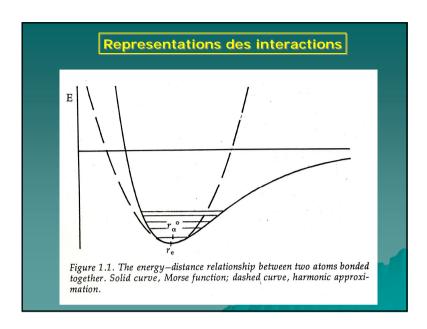
- 4. Sources de paramètres "idéaux"

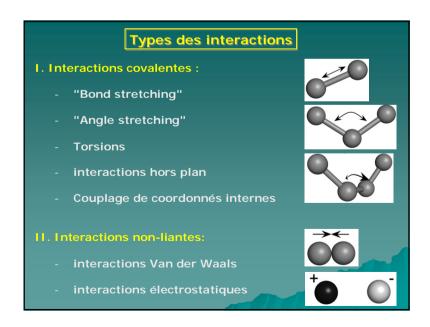
 - mouvements internes:

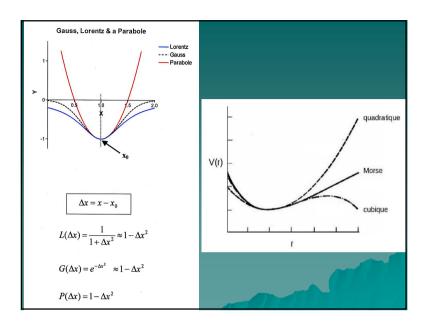


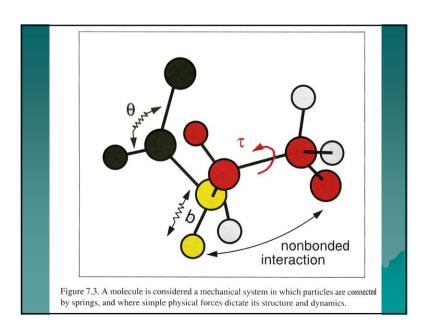
- "shrinkage" :

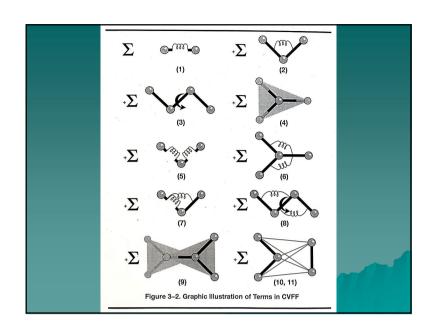
5. Limitations

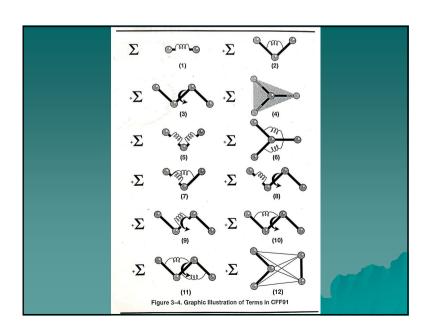












$$E_{pol} = \sum_{b} [K_{2} (b - b_{0})^{2} + K_{3} (b - b_{0})^{3} + K_{4} (b - b_{0})^{4}]$$

$$+ \sum_{\theta} H_{2} (\theta - \theta_{0})^{2} + H_{3} (\theta - \theta_{0})^{3} + H_{4} (\theta - \theta_{0})^{4}$$

$$(2)$$

$$+ \sum_{\phi} [V_{1} [1 - \cos (\phi - \phi_{1}^{0})] + V_{2} [1 - \cos (2\phi - \phi_{2}^{0})] + V_{3} [1 - \cos (3\phi - \phi_{3}^{0})]]$$

$$(3)$$

$$+ \sum_{\chi} \chi \chi^{2} + \sum_{b} \sum_{b'} F_{bb'} (b - b_{0}) (b' - b'_{0}) + \sum_{\theta} \sum_{\theta'} F_{\theta\theta'} (\theta - \theta_{0}) (\theta' - \theta'_{0})$$

$$(4)$$

$$(5)$$

$$(6)$$

$$+ \sum_{b} \sum_{\theta} F_{b\theta} (b - b_{0}) (\theta - \theta_{0}) + \sum_{b} \sum_{\phi} (b - b_{0}) [V_{1} \cos \phi + V_{2} \cos 2\phi + V_{3} \cos 3\phi]$$

$$(8)$$

$$+ \sum_{b'} \sum_{\phi} (b' - b'_{0}) [V_{1} \cos \phi + V_{2} \cos 2\phi + V_{3} \cos 3\phi]$$

$$(9)$$

$$+ \sum_{\theta} \sum_{\theta} \sum_{\theta'} K_{\phi\theta\theta'} \cos \phi (\theta - \theta_{0}) (\theta' - \theta'_{0}) + \sum_{i>j} \frac{q_{i}q_{j}}{er_{ij}} + \sum_{i>j} \left[\frac{A_{ij}}{r_{ij}} - \frac{B_{ij}}{r_{ij}} \right]$$

$$(11)$$

$$(12)$$

$$E_{\text{pol}} = \sum_{b} D_{b} [1 - e^{-\alpha (b - b_{0})}]^{2} + \sum_{\theta} H_{\theta} (\theta - \theta_{0})^{2} + \sum_{\phi} H_{\phi} [1 + s\cos(n\phi)]$$

$$(1) \qquad (2) \qquad (3)$$

$$+ \sum_{\chi} H_{\chi} \chi^{2} + \sum_{b} \sum_{b'} F_{bb'} (b - b_{0}) (b' - b'_{0}) + \sum_{\theta} \sum_{\theta'} F_{\theta\theta'} (\theta - \theta_{0}) (\theta' - \theta'_{0})$$

$$(4) \qquad (5) \qquad (6)$$

$$+ \sum_{b} \sum_{\theta} F_{b\theta} (b - b_{0}) (\theta - \theta_{0}) + \sum_{\phi} F_{\phi\theta\theta'} \cos\phi (\theta - \theta_{0}) (\theta' - \theta'_{0}) + \sum_{\chi} \sum_{\chi'} F_{\chi\chi'} \chi \chi'$$

$$(7) \qquad (8) \qquad (9)$$

$$+ \sum_{\epsilon} [(r^{*}/r)^{12} - 2(r^{*}/r)^{6}] + \sum_{\theta} q_{i} q_{i} / \epsilon r_{ij}$$

$$(10) \qquad (11)$$

